

스마트워치 가속도계 기반 실시간 온디바이스 위험 수준 인식 기법

김승연, 유재현*

성신여자대학교 AI융합학부

20231330@sungshin.ac.kr, *jhyoo@sungshin.ac.kr

Real-time On-device Risk-level Recognition with Smartwatch Accelerometers

Kim Seung Yeon, Yoo Jae Hyun*

School of AI Convergence, Sungshin Women's University

요약

본 논문은 스마트워치 가속도계 신호를 이용해 사용자의 활동을 다단계 위험 수준(1~5 단계)으로 인식하는 온디바이스 기법을 제안한다. 공개 데이터셋과 자체 수집 데이터를 포함한 총 21개 활동을 대상으로, 슬라이딩 윈도우 기반 네 가지 특징을 추출하여 다중 퍼셉트론 분류기를 학습하였다. 실험 결과 정확도 93.9%를 달성하였으며, AI 추론 모델 크기는 약 0.08 MB이고, 추론 지연 1 ms 미만으로 실제 스마트워치에서 실시간 실행 가능함을 확인하였다.

I. 서 론

최근 웨어러블 기기 중 스마트워치는 일상생활에서 가장 보편적으로 활용되고 있으며, 운동 건강 관리를 넘어 개인 안전 모니터링 도구로서의 가능성이 주목받고 있다 [1]. 특히 위험 상황에서는 사용자의 행동을 신속히 파악하여 위험 수준을 감지하는 것이 중요하다.

본 연구에서는 스마트워치에 탑재된 가속도 센서만을 활용하여, 위험 수준을 다단계로 인식하는 경량 온디바이스 기법을 제안한다. 제안 방법은 네 가지 통계적 특징을 사용해 계산 복잡도를 줄이면서도, 실제 기기 내 실시간 추론이 가능함을 검증하였다.

II. 본론

2.1 데이터셋 및 수집

본 연구에서는 공개 벤치마크 데이터셋과 자체 수집 데이터를 함께 활용하였다. 우선, PAMAP2 Physical Activity Dataset의 일부를 사용하여 앉기, 눕기, 서기 등 정직이고 저위험 활동을 확보하였다 [2].

추가적으로, 본 연구의 목적에 맞춰 8명의 참가자를 대상으로 별도의 데이터를 수집하였다. 줄넘기, 전력 질주, 위험 상황 묘사, 급격한 방향 전환과 같은 동적이고 잠재적 위험이 큰 행동을 수행하였다. 데이터는 실내 체육 시설에서 기록되었으며, 가속도계는 50 Hz의 샘플링 속도로 설정되었다. 최종적으로 총 21개의 활동 데이터가 확보되었으며, 이는 위험 수준 1~5 단계로 매핑되어 다양한 상황을 포괄할 수 있도록 구성되었다.

2.2 데이터 전처리

수집된 가속도 데이터는 분석 단위로 활용하기 위해 시간 구간 별로 분할되었다. 본 연구에서는 6초(300 샘플)를 하나의 구간으로 설정하고, 인접 구간은 3초(150 샘플) 간격으로 겹치도록 구성하였다. 중첩 슬라이딩 윈도우 방식은 순간적으로 발생하는 급격한 움직임을 효과적으로 포착하는 동시에, 장시간 신호에서도 안정적으로 특징을 추출할 수 있도록 돋는다. 특히, 위험 상황은 짧은 시간 안에 급격하게 나타날 수 있기 때문에, 이러한 전처리 전략은 실시간 위험 텀지 성능을 향상시키는 핵심적인 역할을 한다.


2.3 특징 추출

각 윈도우 구간에 대해, 3축 가속도 데이터를 통합한 신호 벡터 크기 (Signal Vector Magnitude, SVM)를 계산하였다. SVM은 방향과 무관하게 움직임의 크기를 반영하며 아래 수식과 같이 정의된다.

$$SVM(t) = \sqrt{x(t)^2 + y(t)^2 + z(t)^2}$$

SVM 값을 기반으로 네 가지 특징을 산출하였다. 첫째, SVM 평균은 활동 강도를 정량화하며, 둘째 SVM 표준편차는 움직임의 변동성을 나타낸다. 셋째, 인접 샘플 간 차이의 절댓값(ΔSVM) 평균은 순간적 변동의 빈도를 반영하며, 넷째 ΔSVM 표준편차는 충격성 동작의 강도를 수치화한다.

이 네 가지 특징은 계산량이 적어 실시간 환경에 적합하면서도, 활동 강도와 변동성을 다각도로 설명할 수 있다. 그림 1와 같이 위험 수준이 높아질수록 전반적으로 값이 증가하는 경향을 보인다. 일부 특징에서는 레벨 4와 5가 겹치는 경우가 있으나, 네 가지 특징을 종합적으로 활용할 경우 상호보완적 효과를 통해 안정적이고 신뢰도 높은 위험 수준 구분이 가능함을 확인하였다.



[그림 1] 위험 수준(1~5)에 따른 네 가지 통계 특징의 평균과 표준편차.

2.4 위험 수준 정의

수집된 21개 활동은 위험 수준 1~5의 다단계 지표로 매핑되었다. 정적 인 활동은 수준 1, 보행이나 줄넘기 등 비교적 규칙적이고 반복적인 일상 활동은 수준 2~3으로 구분하였다. 수준 4에는 손목에 순간적인 충격이 크게 가해지는 활동을 포함시켰으며, 수준 5는 실제 위험 상황을 직접 기록하기 어렵다는 점을 고려하여 위험 회피 동작이나 전력 질주와 같은 위험 상황을 가정한 고강도 활동으로 구성하였다. 이러한 단계 구분은 단순히 활동 종류를 분류하는 것을 넘어, 행동이 지니는 상대적 위험성을 반영하기 위한 것이다. 표 1은 각 위험 수준에 매핑된 활동을 정리한 것으로, 낮은 수준은 주로 공개 데이터셋의 정적·저강도 활동, 높은 수준은 직접 수집한 격렬 동작이 포함되어 있다.


수준	표현	행동
1	정적 활동	눕기, 앉기, 서기, TV 시청, 컴퓨터 작업, 운전
2	저강도 일상 활동	다림질, 빨래 개기, 청소, 칠판 작업 (쓰기/지우기), 계단 오르기, 계단 내려가기
3	중강도 활동	자전거 타기, 줄넘기
4	고강도 활동	손바닥 밀기, 격렬한 손바닥 게임
5	격렬/위험 상황	팔벌레 뛰기, 달리기, 지그재그 달리기, 비구조화된 위험 상황

[표 1] 위험 수준(1~5)과 매핑된 활동.

2.5 모델 학습 및 평가

앞서 정의한 네 가지 특징을 입력으로 다중 퍼셉트론(MLP) 분류기를 학습하였다. 설계한 MLP는 3개의 은닉층으로 구성되며, 각 층의 노드 수는 256, 128, 64개이다. 은닉층에서는 ReLU와 Tanh 활성화 함수를 사용하였고, 출력층은 위험 수준 1~5에 대응하는 5개의 노드로 Softmax 함수를 통해 최종 확률 분류를 수행하였다. 학습 과정에서는 다중 클래스 교차 엔트로피 손실 함수와 Adam 최적화 기법을 적용하였으며, Dropout, Batch Normalization, Early Stopping을 통해 과적합을 방지하였다. 또한, 활동별 데이터의 편차를 보정하기 위해 클래스 가중치를 부여하여 학습 시 균형을 유지하였다.

평가 결과, 제안한 분류기는 정확도 93.9%를 달성하였으며, 그림 2의 혼동행렬에서도 대부분의 위험 수준이 구분됨을 확인하였다. 표 2는 위험 수준별 정밀도, 재현율, F1 점수와 지원수를 정리한 것으로, 데이터가 적은 수준에서도 F1 점수가 0.92 이상을 유지되어 고위험 활동 인식에서도 안정적인 성능을 보였다. 최종 AI 추론 모델 크기는 약 0.08 MB이고, 평균 추론 지연은 1 ms 미만으로 측정되어 스마트워치 내에서 실시간 실행이 가능함을 검증하였다.



[그림 2] 제안한 MLP 분류기의 혼동행렬.

	정밀도	재현율	F1 점수	지원수
1	0.9599	0.9423	0.9511	763
2	0.9040	0.9253	0.9146	509
3	0.9270	0.9203	0.9236	138
4	0.9551	0.9659	0.9605	176
5	0.9524	0.9615	0.9569	104

[표 2] 위험 수준(1~5)별 분류 성능 지표 (정밀도, 재현율, F1 점수, 지원수)

2.6 온디바이스 추론 결과 및 후처리

스마트워치에서 실시간 추론을 수행한 결과, 순간적인 노이즈와 원도우 경계 효과로 인해 위험 수준이 짧은 시간 동안 출렁이는 현상이 관찰되었다. 이를 완화하기 위해 경량 후처리 기법을 적용하였다.

첫째, 최근 구간의 확률을 평균하는 smoothing을 통해 단기 변동을 안정화하였다. 둘째, 등급 전환 시 상향은 보수적으로, 하향은 상대적으로 완화하여 적용하는 hysteresis 규칙을 두어 불필요한 진동을 줄였다. 추가적으로 순간적인 스파이크를 억제하는 jerk guard와, 최근 예측의 중앙값을 사용하는 median filter를 적용해 예측의 급격한 흔 현상을 보완하였다.

이러한 후처리 적용 전에는 동일한 활동에서도 위험 수준이 빈번히 변동하였으나, 적용 후에는 일정 수준이 유지되며 결과가 안정적으로 개선됨을 확인하였다. 연산 복잡도는 평균 및 조건 비교 수준에 불과해 전체 지원에는 영향을 주지 않았다. 따라서 제안 기법은 실시간성은 그대로 유지하면서도 안정성을 크게 향상시킬 수 있음을 검증하였다.

III. 결론

본 논문에서는 스마트워치의 가속도계 신호만을 활용하여 활동을 위험 수준 1~5 단계로 인식하는 경량 기법을 제안하였다. 단일 센서와 소형 신경망만으로도 위험 상황을 효과적으로 감지할 수 있음을 실험적으로 확인하였으며, 실제 스마트워치 환경에서 온디바이스 방식으로 원활하게 동작함을 보였다. 또한 순간적 잡음을 억제하는 후처리 과정을 통해 결과의 안정성을 향상시켰다.

향후 연구에서는 위험 상황 시나리오와 사용자 집단을 확대하고, 배터리 소모 및 장기 사용성을 평가함으로써 실용성을 강화할 예정이다. 더불어, 다중 퍼셉트론(MLP) 모델뿐만 아니라 수식 기반 모델을 포함한 다양한 접근법을 적용하여 성능과 효율성을 심층적으로 비교·분석함으로써, 보다 신뢰성 있고 실용적인 위험 상황 탐지 기술로 발전시킬 계획이다.

ACKNOWLEDGMENT

이 논문은 경찰청이 지원한 '사회적 약자 보호 강화 기술 개발 (www.kipot.or.kr)'의 지원을 받아 수행된 연구결과입니다. [과제명: 저전력 복합측위, 근접탐색 기술 기반 범죄피해 안전조치 대상자 위치 추적 통합관제 플랫폼 개발 / 과제번호: RS-2023-00236101].

참 고 문 헌

- S. Masoumian Hosseini, S. T. Goudarzi, S. A. Bagheri, and M. B. Menhaj, "Smartwatches in healthcare medicine: assistance and monitoring; a scoping review," *BMC Medical Informatics and Decision Making*, vol. 23, no. 1, pp. 1–16, 2023.
- A. Reiss and D. Stricker, "Introducing a new benchmarked dataset for activity monitoring," *Proc. 16th Int. Symp. Wearable Computers (ISWC)*, pp. 108–109, 2012.